卫星智能姿态控制系统学习综述

项目名称：人工智能在卫星姿态控制系统中的应用

文稿日期：2026年10月13日。本文对应原立项结题学习综述，区分文献知识、本项目实现和待验证假设。原论文与官方资料的获取和阅读层级见05_来源与核验/文献核对清单.md。

摘要

卫星智能姿态控制并非单一算法，而是把学习方法用于状态估计、模型辨识、控制策略或传统控制器参数选择的不同路径。本文围绕连续力矩姿态控制，介绍神经网络映射、模型学习与混合控制的区别，重点比较PPO、SAC和TD3的目标、样本使用和训练机制，结合真实卫星研究说明历史观测对推断未知动力学的重要性，并讨论域随机化、零动作校准与在线自适应的边界。项目V1/V2形成共同环境、强PID、多训练种子和校准消融；V3完成12份SAC模型与10,920测试回合，全量独立核验通过。仅惯量随机化未扩大本次免重整定范围，三轴保留域外成功率由标称训练的100.0%降至84.4%；标称训练SAC则以较慢响应换取较低控制代价。结果说明智能控制应由独立测试、性能取舍和可复现证据判断，不能只看奖励或一条收敛曲线。

关键词：卫星姿态控制；深度强化学习；SAC；域随机化；泛化评估

1 从人工智能概念到具体控制位置

传统反馈控制根据当前观测和内部状态生成动作。神经网络可以近似这一映射，也可以预测下一状态、估计未知参数、补偿残差或调整PID增益。使用神经网络并不自动构成强化学习；监督学习通常依赖给定输入输出样本，强化学习则通过环境交互的累计回报学习决策策略。

路径	网络输入与输出	需要的训练信号	主要限制
直接策略学习	姿态误差与角速度到力矩	交互轨迹和奖励	探索成本、稳定性与分布外性能
模型辨识	状态动作到下一状态，或轨迹到惯量估计	转移数据或参数标签	可辨识性、噪声和模型偏差
残差或混合控制	观测到补偿力矩或PID增益	专家数据或奖励	叠加后安全性及贡献归因
姿态估计辅助	传感器数据到姿态或误差修正	参考姿态、观测一致性等	数据分布、标定及误差传播

模型辨识后接模型预测控制，需要有可用于预测的模型，并在滚动时域中优化未来动作；直接用PPO或SAC输出力矩并没有完成这一框架。Xu等的卫星控制研究在摘要中明确采用基于模型的学习与启发式搜索[1]，说明“智能控制”内部也有不同的模型使用方式。本文仅取得该论文摘要，不复述未经核实的实验设置或具体优势数值。

原立项还列出了神经网络和融合模型学习。本项目当前正式实验是直接策略强化学习，网络作为策略和价值函数近似器，不另有已验证的神经动力学模型或神经PID。关于这些方向的分类

属于学习综述，不能写成已经实现的算法成果。

2 把姿态控制表述为序列决策问题

令x_t为完整物理状态，o_t为控制器可见观测，a_t为归一化动作。单轴观测是角误差和角速度；三轴观测是本体系最短目标修正向量和角速度。环境把连续动作映射到受限物理力矩，再按动力学更新状态。基础目标为最大化

$$J(\pi)=\mathbb{E}_{\pi}\left[\sum_{t=0}^{T-1}\gamma^{t}r_{t}\right].$$

在未知惯量、外扰或噪声下，当前观测未必包含决定下一状态分布所需的全部信息。例如两个卫星具有同样的角误差和角速度，但惯量不同，对同样力矩的响应也不同。因此严格地说，给策略的瞬时观测可能形成部分可观测问题。把环境包装成Gym接口，不等于证明这些观测满足马尔可夫性质。

Gymnasium规定reset返回观测与信息，step返回观测、奖励、terminated、truncated和信息[2]。物理发散或任务内终止与外部时间限制截断的学习含义不同：在适当的继续任务建模下，时间截断后仍需价值自举，真正终止则不自举[3]。把两者混为一个done会改变价值学习。项目采用固定20 s部署评价，达到阈值不提前结束，从而测量持续保持而非第一次到达。

3 神经策略与奖励设计

多层感知机通过层间加权和与非线性激活，把o_t映射为动作分布或动作值。策略网络负责“做什么”，价值网络估计长期回报，二者在Actor-Critic框架中协同更新。网络参数多并不意味着更精确；尺度、数据覆盖和优化目标往往同样重要。

项目共同奖励为

$$r_t=-(6\|e_t\|^2+0.6\|\omega_t\|^2+0.03\|\tau_t\|^2),$$

姿态和角速度以弧度制计算，奖励使用本步动作后的真实误差与角速度，以及该步实际施加力矩；控制器仍只接收配置所规定的观测。首次物理发散另扣1000。误差项推动接近目标，角速度项鼓励停止，力矩项抑制过大动作。权重是本项目设置，不能称为数学证明的最优权衡。奖励变好也不必然满足“末5 s每个采样点达标”，因此最终验收使用独立的物理指标。

若仅把所有未完成回合给负奖励，且发散能提前终止，策略可能通过快速失败逃避后续代价；发散惩罚和正确终止语义可降低这种漏洞，但仍需检查失败轨迹。奖励中的力矩平方也不能直接叫实际能量，相关区别在搭建综述中已说明。

Stable-Baselines3建议检查自定义环境、合理缩放观测和连续动作，并做多随机种子评价[4]。V2/V3采用弧度制观测与统一的动作映射；动作归一化不等于实现了运行统计的观测标准化，正式报告按实际包装器记录，不能笼统宣称使用了VecNormalize。

4 PPO如何更新策略

PPO以当前策略采样轨迹，再用这批数据进行多个小批次更新，属于on-policy方法。Schulman等给出的裁剪目标为[5]

$$L^{\mathrm{CLIP}}(\theta)=\mathbb{E}_t\left[\min\left(r_t(\theta)\hat{A}_t,\ \mathrm{clip}(r_t(\theta),1-\varepsilon,1+\varepsilon)\hat{A}_t\right)\right],\quad r_t(\theta)=\frac{\pi_\theta(a_t|o_t)}{\pi_{\theta_{\mathrm{old}}}(a_t|o_t)}.$$

这里r_t(θ)是概率比，与前文奖励r_t同名但含义不同，阅读公式需区分。优势估计Â_t评价某动作相对通常表现有多好；裁剪目标限制继续放大某些过大策略变化的收益。它不是把网络参数更新量简单截断，也不提供航天器全局稳定保证。

PPO实现相对直接，适合做首个连续控制原型，但旧轨迹通常不能像off-policy算法那样长期重复使用。采样环境快时这可能可接受，真实航天器在线探索则会有成本和安全约束。本项目使用仿真训练，不主张把未验证探索直接放到在轨系统中。

5 SAC的最大熵学习

SAC使用经验回放学习随机策略和价值函数，目标同时包含累计奖励与策略熵[6]：

$$J_{\mathrm{SAC}}(\pi)=\mathbb{E}\left[\sum_t \gamma^t\left(r_t+\alpha\mathcal{H}(\pi(\cdot|o_t))\right)\right].$$

熵项鼓励探索，α控制其相对重要性。经验回放可以重用过去的转移数据，提高交互样本利用率；双Q等机制有助于减轻价值估计过高，但神经函数近似下仍可能训练失败或出现种子波动。

本文实现采用SB3 2.7.1的SAC，使用双Q目标与自动熵系数。双Q在最早SAC论文中已经使用；相对该论文的网络版本，SB3不再单独拟合状态价值V网络，并通过优化熵系数的对数来自动调整温度。官方文档说明熵系数处理，其固定版本源码可核对实现[7]。因此不能说“逐行复现2018最早SAC论文”。训练中的随机探索与测试中的确定性推理也应分开记录，测试时不继续加入训练探索噪声。

选SAC作为V3主算法，依据是V2校准后三轴学习策略中相对较好的保持成功率和末段误差，同时它的控制代价高于校准PPO，成功率仍低于改进PID。算法选择是针对已测任务的取舍，而非证明SAC普遍最优。

6 TD3怎样减轻价值误差

TD3是在确定性Actor-Critic连续控制中，针对函数近似误差和过估计提出的改进[8]。其三个关键措施是双价值网络取较小目标、延迟策略更新和目标策略平滑。一个典型目标形式为

$$y=r+\gamma(1-d)\min_{i=1,2}Q'_i(o',\mathrm{clip}(\mu'(o')+\varepsilon)).$$

d表示真正终止，ε是受限的目标动作噪声，动作还需服从允许区间。目标平滑噪声不同于收集训练数据时的探索噪声；延迟策略更新是让价值估计先更新，并不等于降低仿真频率。TD3的理论动机不能替代本项目验证，当前有限预算下出现较大种子差异就应保留。

方法	轨迹使用	策略形式	本项目比较时需注意
PPO	新策略采样，重复若干epoch	随机策略	rollout会让实际步数略超过请求值
SAC	经验回放	最大熵随机策略	熵系数、回放量与确定性推理设置
TD3	经验回放	确定性策略	双Q、延迟更新与两种噪声的区别

相同环境交互步数是共同预算的一种口径，但三者梯度更新、网络数量和运行时间不同，不能称相同计算量。SB3内部_n_updates在不同算法中口径也不同，报告保留日志但不横向当作同定义的更新次数。[9]给出了该库的实现与测试背景，使用成熟库仍需核验自己的环境与比较条件。

7 域随机化能做什么 不能做什么

域随机化在训练时从预定分布抽取环境参数，希望策略在一组模型上形成可用控制。Tobin等的工作随机化渲染条件，研究视觉模型从模拟图像到真实图像的迁移[10]；Peng等随机化动力学参数，研究机械臂推物任务的策略迁移[11]。二者都是相关方法来源，但任务和观测不同，不能把机器人的实物迁移结论直接算成本项目卫星验证。

可以把随机化目标写为

$$\max_{\pi} \mathbb{E}_{\rho\sim p_{\text{train}},\, x_0}[J(\pi;\rho,x_0)].$$

这优化训练分布上的平均回报，不自动保证最坏工况，也不保证训练域外。随机范围过窄可能覆盖不足，过宽可能增加优化难度或损失标称精度。Zhao等的综述把域随机化、域适应、模仿学习等区分为不同迁移路径[12]，进一步说明“做过随机化”不等于解决了现实差距。

本项目V2同时改变惯量、外扰和噪声，能研究综合压力表现，却难单独归因于惯量随机化。V3固定算法、网络、奖励、预算和初态分布，只比较标称惯量与每回合ρ∼U[0.7,1.3]的训练。测试端点0.7、1.3仍是域内；0.5、0.6、1.4、1.5作为本轮保留域外测试，未参与选模或PID整定。

一次回合内惯量不变，跨惯量部署时不改权重、增益和校准偏置，这称免重整定或固定策略鲁棒性。策略只读瞬时观测，不估计真实惯量，没有在线更新律，因此不称在线辨识或自适应控制。

8 真实卫星文献怎样帮助界定本项目

Retagne、Dauer和Waxenegger-Wilfing研究质量变化下的卫星姿态控制，使用Basilisk仿真和SAC/PPO，并通过堆叠过去的观测及动作，让策略获得推断动力学的信息[13]。原文明确把隐藏物理属性、历史信息和控制表现联系起来，采用Monte Carlo评估；模型还包含反作用轮，而本文项目目前直接施加理想力矩。

这篇文献提示两个可学习的方向。第一，未知惯量不是仅增加随机参数就自动可观测，需要考虑历史、激励和策略结构。第二，比较应该报告多个场景和失败条件，而非只画最优轨迹。本

项目不复现该论文，不沿用其性能数值，也不能把其“adaptive”称谓直接移植到自己的无记忆策略。

V3的科学问题更窄：在预定仿真和持续保持标准下，惯量随机化是否扩大固定控制策略的经验可用网格范围。这一问题不要求AI获胜；若充分整定的固定PID同样鲁棒，或SAC出现种子波动，都是应解释的研究结果。

9 部署校准与学习改进必须分开

神经策略在o=0，即零姿态误差与零角速度时，可能仍输出非零动作。V2采用

$$a_{\mathrm{cal}}(o) = \mathrm{clip}(a_{\mathrm{raw}}(o) - a_{\mathrm{raw}}(0), -1, 1).$$

该操作固定名义参考点的零动作，不改变网络权重，不读取真实惯量，也不引入积分状态。它是本项目的部署后处理对照，既不称新强化学习算法，也不援引文献暗示原创性。若存在持续外扰，目标处可能需要非零平衡力矩；减去策略偏置不保证有益，也不能代替扰动估计。

校准后的结果应与同检查点、同种子、同场景的原始动作配对。V2所有原始与校准版本都保留，V3也固定相同规则。若检查点按校准后验证分数选择，则原始动作消融只是同检查点比较，不能称原始SAC自身的最优选模结果。

10 怎样形成可信的实验结论

训练集用于更新网络，验证集用于选检查点和控制参数，最终测试用于评价冻结后的方法。已经查看过的V1/V2数据可作为V3设计依据，但不能冒充V3从未见过的新测试。V3重新生成初态并保留域外惯量；这些数据在控制器冻结后才用于一次正式测试。

至少保留三个独立训练种子，把全部种子纳入结果。每个种子在大量场景上的测试，不能替代大量独立训练重复；三个种子的标准差是描述性波动，不是普遍显著性证据。同一初态跨多个惯量复用用于配对，也不能全部算作独立初态样本。

PID和RL需要相同可见观测、物理约束和测试场景。PID应充分整定，整定预算与候选可追溯。原始PID、整定PID和额外滤波的作用分别展示，不能把全部改善归给某个单独技巧。控制成功率、全程RMS、末段误差、有效时长与控制代价同时报告；稳定时间只对成功回合统计时，应说明不同控制器可能对应不同成功子集。

V3预定经验阈值为一个惯量点成功率≥90%，单个种子需30初态中至少27个成功，保守汇总要求三个种子都达标。可用区间由包含 ρ =1的连续通过网格构成；若全部已测0.5—1.5通过，只能说覆盖已测范围，没有找到真正失效边界，更不能保证网格之间任意惯量均通过。

11 本项目已经形成的认识

V1名义条件下普通PPO的控制代价比当时PID低9.4%，但这只是V1基线与工况下的描述。V2使用更强PID、多算法和严格保持标准后，校准RL的最高总体成功率单轴68.9%、三轴63.0%，分别低于改进PID的71.1%和72.8%。不同版本条件不相同，不能拼成一个统一排名。

V2三轴SAC同模型校准把成功率由0提升到63.0%，末段误差由3.055°降到0.085°；这是部署后处理的实测作用，不是原始SAC训练性能。其控制代价高于改进PID，体现了精度、响应和保持可靠性之间的取舍。严格评价揭示失败和代价，并不使项目失去价值，反而帮助识别真正需要研究的问题。

V3完成两轴×两种训练分布×三个种子的12份从零训练SAC模型，每份100万交互步，以及10,920正式测试回合；全量独立核验通过。两种训练模式均在共同域内验证集按校准部署分数选检查点，原始动作使用同一检查点做消融，不能当作原始SAC自身的最优选模。

主结论均对应校准部署策略。保留域外测试中，单轴SAC-N/SAC-R成功率100.0%/98.9%，共同可用网格均11点；三轴100.0%/84.4%，共同网格由11缩至7点，即0.5—1.1倍。两类PID域外均100.0%成功。三轴随机化组的标量失败集中在种子33的角速度保持超限，未发生物理发散；该种子最高验证成功率也只有85%，按预定规则保留，而非事后删除。

标称训练SAC与PID-N域外均成功时，平均控制代价单轴降低54.7%、三轴降低28.7%，但稳定时间分别由3.26 s增至4.26 s、3.23 s增至6.19 s，RMS由6.38°增至7.08°、9.16°增至11.70°。因此较低力矩负担不等于全指标优势或实际节电。非等比例三轴迁移中，SAC-N成功率100.0%、SAC-R为85.8%，此压力测试不纳入标量边界。

本次未观察到仅惯量随机化扩大免重整定范围，现有证据只描述训练波动与高惯量保持不足，没有额外因果实验确定其优化机制。全部已测网格通过的对象只获得0.5—1.5倍有限范围内的证据，尚未找到真实边界。本项目贡献定位是可复现的姿态控制对照、消融和边界评价，尚未提出新的PPO/SAC/TD3算法，也未完成真实卫星部署。

12 后续研究方向

若后续研究确有资源，可以加入历史观测或递归策略，与瞬时观测策略做受控对照，再研究隐式动力学推断。也可独立开展模型辨识和预测控制，但需要新的数据、识别误差和闭环验证。硬件迁移前应接入真实传感器与执行器特性、延迟及安全机制，不能仅扩大仿真参数范围就宣称完成迁移。结项阶段优先冻结可靠结果、核实文献并完成可复现交付。

参考文献

[1] XU K, WU F, ZHAO J. Model-based deep reinforcement learning with heuristic search for satellite attitude control[J]. Industrial Robot, 2019. DOI:10.1108/IR-05-2018-0086. https://doi.org/10.1108/IR-05-2018-0086 （核对Crossref元数据及摘要，未获取全文）。

[2] Farama Foundation. Gymnasium Env API[EB/OL]. https://gymnasium.farama.org/api/env/ （访问2026-10-13）。

[3] Farama Foundation. Handling Time Limits[EB/OL]. https://gymnasium.farama.org/tutorials/gymnasium_basics/handling_time_limits/ （访问2026-10-13）。

[4] Stable-Baselines3 Contributors. Reinforcement Learning Tips and Tricks[EB/OL]. https://stable-baselines3.readthedocs.io/en/master/guide/rl_tips.html （访问2026-10-13）。

[5] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal Policy Optimization Algorithms[EB/OL]. 2017. arXiv:1707.06347. https://arxiv.org/abs/1707.06347 （已读摘要及全文裁剪目标、算法与实验说明）。

[6] HAARNOJA T, ZHOU A, ABBEEL P, LEVINE S. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[C]. ICML, 2018, PMLR 80:1861-1870. https://arxiv.org/abs/1801.01290 （已读最大熵目标、soft policy iteration及实现部分）。

[7] Stable-Baselines3 Contributors. SAC Documentation and version 2.7.1 source[EB/OL]. https://stable-baselines3.readthedocs.io/en/master/modules/sac.html ; https://raw.githubusercontent.com/DLR-RM/stable-baselines3/v2.7.1/stable_baselines3/sac/sac.py （访问2026-10-13）。

[8] FUJIMOTO S, VAN HOOF H, MEGER D. Addressing Function Approximation Error in Actor-Critic Methods[C]. ICML, 2018, PMLR 80:1587-1596. https://arxiv.org/abs/1802.09477 （已读双Q、延迟更新和目标平滑部分）。

[9] RAFFIN A, HILL A, GLEAVE A, et al. Stable-Baselines3: Reliable Reinforcement Learning Implementations[J]. Journal of Machine Learning Research, 2021, 22(268):1-8. https://www.jmlr.org/papers/v22/20-1364.html （已读JMLR页面摘要及书目）。

[10] TOBIN J, FONG R, RAY A, et al. Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World[EB/OL]. 2017. arXiv:1703.06907. https://arxiv.org/abs/1703.06907 （已读摘要、随机化方法与任务说明）。

[11] PENG X B, ANDRYCHOWICZ M, ZAREMBA W, ABBEEL P. Sim-to-Real Transfer of Robotic Control with Dynamics Randomization[EB/OL]. 2017初稿，2018修订. arXiv:1710.06537. https://arxiv.org/abs/1710.06537 （已读动力学抽样、记忆策略与实验设计部分）。

[12] ZHAO W, QUERALTA J P, WESTERLUND T. Sim-to-Real Transfer in Deep Reinforcement Learning for Robotics: a Survey[EB/OL]. 2020初稿，2021修订. arXiv:2009.13303. https://arxiv.org/abs/2009.13303 （此次已读摘要，不引用未核实的全文细节）。

[13] RETAGNE W, DAUER J, WAXENEGGER-WILFING G. Adaptive satellite attitude control for varying masses using deep reinforcement learning[J]. Frontiers in Robotics and AI, 2024, 11:1402846. DOI:10.3389/frobt.2024.1402846.

https://www.frontiersin.org/journals/robotics-and-ai/articles/10.3389/frobt.2024.1402846/full （已读2.5历史观测、3方法与仿真架构、结果与局限相关部分）。

项目内部证据

V1：06_结项说明与报告/结项技术报告.md及对应模型与数据。V2：07_单轴三轴多算法对比/新融合分析.md、原始CSV、校准配对表与核验记录。V3：08_惯量域随机化与泛化边界研究/05_研究分析与核验/研究分析.md、核心结论.json与状态为passed的独立核验记录.json。本文对文献的整理不代表每名成员已亲自完成阅读，真实学习贡献由本人确认。